

1. DESCRIEREA PROIECTULUI

1.1 Contextul și Motivația

Oboseala la volan reprezintă una dintre principalele cauze ale accidentelor rutiere la nivel global. Conform Organizației Mondiale a Sănătății, aproximativ 20% din accidentele grave de circulație sunt cauzate de oboseala conducătorilor auto. În România, studiile arată că peste 15% din accidentele mortale sunt asociate cu somnolența la volan.

Dezvoltarea unui sistem automatizat de detecție a oboselii poate contribui semnificativ la reducerea acestor incidente prin alertarea în timp real a șoferilor asupra stării lor de vigilență diminuată.

1.2 Obiectivul General

Dezvoltarea unui sistem inteligent de detecție a oboselii la șoferi în timp real, bazat pe analiza video a caracteristicilor faciale și comportamentale, utilizând tehnici de Computer Vision și Machine Learning.

1.3 Obiective Specifice

- Implementarea modului de detecție și tracking facial în timp real
- Extragerea automată a caracteristicilor relevante pentru detectarea oboselii (EAR, MAR, poziție cap)
- Antrenarea și compararea mai multor modele de clasificare Machine Learning
- Dezvoltarea unui sistem de alertare progresiv în timp real
- Evaluarea riguroasă a performanței sistemului pe date reale și diverse scenarii

2. METODOLOGIE ȘI ABORDARE TEHNICĂ

2.1 Arhitectura Sistemului

Sistemul va fi structurat modular, cu următoarele componente principale:

1. Modul de Achiziție Video

- Capturare flux video în timp real (cameră web/smartphone)

2. Modul de Procesare Computer Vision

- Detecție facială și extragere facial landmarks

3. Modul de Extragere Features

- Calcul parametri: EAR, MAR, poziție cap, frecvență clipit

4. Modul de Clasificare ML

- Predicție stare oboseală (Random Forest, SVM, XGBoost)

5. Modul de Decizie și Alertare

- Logică temporală și sistem de alerte progresive

2.2 Caracteristici Monitorizate

Parametri Primari:

- **Eye Aspect Ratio (EAR)** - raportul geometric între dimensiunile ochiului pentru detectarea închiderii pleoapelor. Formula: $EAR = (||p2-p6|| + ||p3-p5||) / (2||p1-p4||)$, unde p1-p6 sunt coordonatele celor 6 puncte caracteristice ale ochiului
- **Frecvența și durata clipitului** - număr de clipiri pe minut și timpul de închidere a ochilor (pragul normal: 2-3 secunde pentru semnal de alarmă)
- **Mouth Aspect Ratio (MAR)** - pentru detectarea căscatului ca indicator de oboseală

Parametri Secundari:

- Poziția capului (unghiuri pitch, yaw, roll) față de poziția de referință
- Deviația standard a mișcărilor capului în timp
- Pattern-uri temporale de comportament (variații în perioade de 30-60 secunde)

2.3 Tehnologii și Instrumente

Computer Vision:

- **OpenCV 4.x** - procesare video, transformări geometrice, calibrare cameră
- **MediaPipe** (alternativ dlib) - detecție facial landmarks cu 468 puncte de referință, optimizat pentru performanță real-time

Machine Learning:

- **scikit-learn** - Random Forest Classifier, Support Vector Machine (SVM)
- **XGBoost** - gradient boosting classifier pentru performanță superioară
- **TensorFlow/Keras** (opțional) - pentru implementarea CNN (Convolutional Neural Network)

Procesare și Vizualizare Date:

- **Python 3.8+** - limbaj principal de dezvoltare
- **NumPy, Pandas** - manipulare și analiză date

- **Matplotlib, Seaborn** - vizualizări grafice și rapoarte

2.4 Modele de Machine Learning

Se vor antrena și compara următoarele modele pentru a identifica cea mai bună abordare:

1. Random Forest Classifier

- Robust la overfitting prin agregare de decision trees
- Oferă feature importance pentru interpretabilitate
- Performanță bună fără tuning extensiv

2. Support Vector Machine (SVM)

- Eficient pentru clasificare binară/multi-class
- Kernel RBF pentru capturarea relațiilor non-liniare
- Bine fundamentat teoretic

3. XGBoost

- Performanță de top în competiții ML
- Regularizare încorporată pentru prevenirea overfitting-ului
- Handling automat al missing values

4. Convolutional Neural Network (CNN) - opțional

- Învățare end-to-end direct din imagini
- Extragere automată de features ierarhice
- Potențial pentru acuratețe superioară cu date suficiente

2.5 Pipeline de Procesare

Video Input → Face Detection → Landmark Extraction →

Feature Calculation → Feature Vector Assembly →

ML Classifier → Drowsiness Probability →

Temporal Decision Logic → Alert System

3. DATE DE ANTRENARE ȘI TESTARE

3.1 Dataset-uri Existente Identificate

Pentru antrenarea și validarea sistemului, se vor utiliza următoarele dataset-uri publice:

1. MRL Eye Dataset

- **Conținut:** 84.898 imagini cu ochi (deschisi/închiși)
- **Rezoluție:** Imagini de calitate variată, 24x24 până la 150x150 pixeli
- **Diversitate:** 37 de subiecți, condiții de iluminare diverse
- **Sursa:** <http://mrl.cs.vsb.cz/eyedataset>
- **Utilizare:** Antrenare clasificator ochi deschisi/închiși

2. NTHU Drowsy Driver Detection Video Dataset

- **Conținut:** Video-uri cu șoferi în condiții de condus simulate
- **Adnotări:** Timestamp-uri pentru comportament obosit/alert
- **Scenarii:** Diferite ore ale zilei, tipuri de șoferi
- **Utilizare:** Validare sistem complet, testare pattern-uri temporale

3. YawDD (Yawning Detection Dataset)

- **Conținut:** Video-uri pentru detectarea căscatului
- **Clase:** Talking, yawning, normal
- **Sursa:** Disponibil pe Kaggle
- **Utilizare:** Antrenare detector MAR (Mouth Aspect Ratio)

3.2 Colectare Date Proprii (opțional pentru completare – dacă timpul imi va permite)

Pentru a completa dataset-urile existente și a testa sistemul în condiții mai aproape de realitate:

- **Voluntari:** 15-20 persoane
- **Scenarii simulate:** alert (după odihnă), ușor obosit (după 2-3 ore activitate), foarte obosit (după lipsa de somn)
- **Durata:** 5-10 minute de înregistrare per participant per scenario
- **Condiții variate:** Cu/fără ochelari, luminozitate diferită (zi/noapte), unghiuri ușor diferite ale camerei
- **Considerații etice:** Consimțământ informat GDPR, anonimizare date, utilizare strict în scop educațional

3.3 Pregătirea Datelor

Procesare preliminară:

- Extragere frame-uri din video (5-10 FPS pentru etichetare)
- Normalizare și resize imagini la dimensiune constantă
- Eliminare frame-uri cu detecție eșuată sau calitate proastă
- Etichetare: alert (0), obosit ușor (1), obosit sever (2)

Augmentare date (pentru robustețe):

- Rotații ușoare (± 10 grade)
- Schimbări de luminozitate și contrast
- Blur gaussian pentru simulare mișcare
- Flip orizontal (păstrare simetrie facială)

Balansare clase:

- Analiză distribuție clase în dataset
- Aplicare SMOTE (Synthetic Minority Over-sampling Technique) dacă necesar
- Class weights în antrenare pentru compensare dezechilibre

Împărțire date:

- **70% antrenare** - pentru învățarea modelelor
- **15% validare** - pentru tuning hiperparametri și early stopping
- **15% testare** - pentru evaluare finală, date complet nevăzute

4. METODOLOGIA DE TESTARE ȘI EVALUARE

4.1 Metrici de Performanță

Sistemul va fi evaluat folosind următoarele metrici standard din Machine Learning:

Accuracy (Acuratețe)

- Procentul de predicții corecte din totalul predicțiilor
- Formula: $(TP + TN) / (TP + TN + FP + FN)$

Precision (Precizie)

- Din toate cazurile prezise ca "obosit", câte sunt cu adevărat obosite
- Formula: $TP / (TP + FP)$

Recall (Sensibilitate)

- Din toate cazurile reale de oboseală, câte sunt detectate corect
- Formula: $TP / (TP + FN)$

F1-Score

- Media armonică între Precision și Recall
- Formula: $2 \times (Precision \times Recall) / (Precision + Recall)$

Confusion Matrix

- Matrice pentru analiza detaliată a erorilor (false positive vs false negative)

ROC Curve și AUC

- Curba ROC (Receiver Operating Characteristic) și aria de sub curbă pentru evaluarea capacității de discriminare

Timp de Inferență (FPS)

- Viteza de procesare pentru aplicații real-time (țintă: minim 20-30 FPS)

Notății din Confusion Matrix

TP (True Positive) = Adevărat Pozitiv

- Cazuri pe care modelul le-a prezis ca "obosit" și într-adevăr erau obosite
- Predicție corectă pentru clasa pozitivă

TN (True Negative) = Adevărat Negativ

- Cazuri pe care modelul le-a prezis ca "alert" și într-adevăr erau alerte
- Predicție corectă pentru clasa negativă

FP (False Positive) = Fals Pozitiv (Eroare de tip I)

- Cazuri pe care modelul le-a prezis ca "obosit" dar de fapt erau alerte
- Modelul a dat o alarmă falsă
- În contextul tău: sistemul alertează șoferul deși nu este obosit

FN (False Negative) = Fals Negativ (Eroare de tip II)

- Cazuri pe care modelul le-a prezis ca "alert" dar de fapt erau obosite
- Modelul a ratat o situație periculoasă

- În contextul tău: sistemul NU alertează șoferul deși este obosit (PERICULOS!)

4.2 Strategii de Validare

K-Fold Cross-Validation:

- Împărțire date de antrenare în $K=5$ sau $K=10$ fold-uri
- Antrenare pe $K-1$ fold-uri, validare pe fold-ul rămas
- Repetare proces pentru toate combinațiile
- Calculare medie și deviație standard pentru metrici
- **Avantaj:** Utilizare maximă a datelor, estimare robustă a performanței

Testare pe Date Nevăzute:

- Set de test complet separat, niciodată folosit în antrenare
- Evaluare finală a modelului antrenat pe întreg dataset-ul de training
- Raportare metrici pe acest set pentru comparație obiectivă

Testare în Condiții Reale:

- Video live cu voluntari în scenarii simulate de condus
- Evaluare latență sistem (delay între oboseală reală și alertă)
- Testare robustețe: ochelari, luminozitate variată, mișcare cameră
- Feedback utilizatori despre rate de false alarms

4.3 Ablation Study (Studiu de Ablație)

Pentru a înțelege contribuția fiecărui feature la performanța finală:

- Antrenare model cu toate features → baseline performance
- Antrenare modele eliminând câte un feature pe rând
- Comparație drop în performanță pentru fiecare feature eliminat
- Identificare features cele mai importante vs redundante
- Optimizare: păstrare doar features semnificative pentru viteză crescută

Exemple de experimente:

- Model doar cu EAR vs model complet

- Impact adăugare MAR (căscat)
 - Importanță poziție cap vs features oculare
-

5. REZULTATE AȘTEPTATE

La finalizarea proiectului, se vor livra următoarele rezultate:

- **Sistem funcțional de detecție în timp real** capabil să proceseze video la minimum 20-30 FPS pe hardware mediu (laptop standard)
- **Acuratețe minimă 85-90%** pe dataset de test pentru clasificarea stării de oboseală
- **Documentație tehnică completă** incluzând: cod sursă comentat, ghid de instalare și utilizare, documentație API, raport de performanță
- **Comparație riguroasă între modele ML** cu tabele, grafice și analiză statistică pentru: accuracy, precision, recall, F1-score, confusion matrix, ROC curves, feature importance
- **Raport de cercetare academic** structurat conform standardelor pentru lucrări de licență, incluzând state-of-the-art, fundamentare teoretică, rezultate experimentale și concluzii